

# LU3I026 - Science des données

## Apprentissage et modèles

Olivier Schwander <[olivier.schwander@sorbonne-universite.fr](mailto:olivier.schwander@sorbonne-universite.fr)>

Sorbonne Université

2024-2025

# Types d'apprentissage

## Apprentissage supervisé

- ▶ Données
- ▶ Étiquettes
- ▶ Exemple: des images, et le nom de l'objet dans l'image
- ▶ Difficulté: obtenir les étiquettes...

## Apprentissage non-supervisé


- ▶ Juste les données
- ▶ Pas d'étiquettes

## Autres


- ▶ Semi-supervisé
- ▶ Renforcement
- ▶ Auto-supervisé

# Types d'apprentissage


Supervisé      Non-supervisé      Semi-supervisé      Renforcement




Supervised Learning Algorithms



Unsupervised Learning Algorithms



Semi-supervised Learning Algorithms



## Première chose à déterminer




- ▶ conditionne les choix d'algorithmes et de méthodes
- ▶ et les mesures de performances

# Tâches d'apprentissage

Régression

Classification

Ordonnancement



## Autres tâches

- ▶ Souvent des cas particuliers des tâches précédentes
- ▶ Image: segmentation (classif), localisation (régression)
- ▶ Texte: génération (classif), dialogue (ordonnancement)

## Deuxième chose à déterminer

- ▶ Conditionne les choix précis de modèles
- ▶ Permet de fixer le protocole expérimental
- ▶ Ensuite, on peut réfléchir aux modèles

# Premier modèle: linéaire

## Dépendance linéaire entre l'entrée et la sortie

- ▶ Dans un espace vectoriel de dimension  $d$ , soit un point  $x \in \mathbb{R}^d$
- ▶  $f_w(x) = \sum_{i=1}^d w_i x_i$
- ▶  $f$  est le *modèle*
- ▶  $w$  est le vecteur de *paramètres*

## Apprentissage

- ▶ À partir des données
- ▶ Trouver le meilleur  $w$

## Abus de langage

- ▶ Linéaire:  $y = ax$
- ▶ Affine:  $y = ax + b$
- ▶ **Attention** en TP !

# Régression linéaire

- ▶ Avec **UN** point:  $\mathbf{x} = (x_1, \dots, x_d)$
- ▶ Une étiquette  $y \in \mathbb{R}$
- ▶ Approcher l'étiquette  $y$  avec un modèle  $f(x)$

## Apprentissage supervisé

- ▶ À partir de  $N$  points  $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\}$
- ▶ Et leur label  $y_1, \dots, y_N$
- ▶ Chercher le meilleur compromis

## Classification linéaire

- ▶ Avec **UN** point:  $\mathbf{x} = (x_1, \dots, x_d)$
- ▶ Une étiquette  $y \in \{-1, +1\}$
- ▶ Retrouver l'étiquette  $y$  avec un modèle  $\text{signe}(f(\mathbf{x}))$

avec  $\text{signe}(x) = +1$  si  $x \leq 0$  et  $-1$  sinon

### Apprentissage supervisé

- ▶ À partir de  $N$  points  $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\}$
- ▶ Et leur label  $y_1, \dots, y_N$
- ▶ Chercher le meilleur compromis

### Géométriquement

- ▶ Tracer les points
- ▶ Tracer la frontière de décision
- ▶ À quoi correspond la somme ?

# Plus proche voisin

Nearest neighbor

Idée

Associer un nouveau point à l'exemple connu le plus proche  
[Au tableau]



# $k$ -plus proches voisins

## Algorithme

- ▶ Pour un nouveau point
- ▶ Calculer toutes les distances entre ce point et les points connus
- ▶ Rechercher les  $k$  plus proches voisins
- ▶ Aggréger: vote (classification), moyenne (régression)

[Au tableau]

# Analyse

## Complexité algorithmique

- ▶ Temps, espace

## Performances

- ▶ Influence du  $k$
- ▶ Score et généralisation

[Au tableau]

# Modèle linéaire

Classifieur binaire: deux sorties  $+1$  ou  $-1$

## Hyperplan

- ▶ en dimension  $d$
- ▶ équation  $\sum_{i=1}^d w_i x_i = 0$
- ▶  $(w_1, \dots, w_d)$  vecteur normal

## Décision (ou inférence, ou prédiction)

- ▶ De quel coté est-on par rapport à la droite ?
- ▶ Produit scalaire entre le point à classer et le vecteur normal:  
signe de  $\sum_{i=1}^d w_i x_i$
- ▶ Si positif:  $+1$
- ▶ Si négatif:  $-1$

## Comment apprendre ?

# Apprentissage ?

## Paramètres du modèle

- ▶ Caractérise les frontière de décision
- ▶ Permet de prendre la décision
- ▶ Ici les  $w_i$

## Apprentissage

- ▶ Choisir ces paramètres
- ▶ À partir des données
- ▶ Objectif: chercher les meilleurs paramètres

# Moins de linéarité

## Hyperplan linéaire

- ▶ Passe par l'origine
- ▶ C'est  $w \cdot x = 0$  dans l'équation

## Modèle affine

- ▶  $\sum_{i=1}^d w_i x_i = b$
- ▶  $b$ : **biais**

## Comment choisir ce biais ?

- ▶ L'apprendre comme les  $w$ : paramètre
- ▶ Le fixer à l'avance: **hyper-paramètre**

# Linéarité: suffisant ou pas ?

[Au tableau]

# Hyperplan aléatoire

## Paramètres

- ▶ Vecteur normal  $w$
- ▶ Éventuellement biais  $b$

## “Apprentissage”

- ▶ Tirer aléatoirement un vecteur  $w$  (avec  $\|w\|$  suffisamment grand)
- ▶ Pas vraiment de l'apprentissage: ne dépend pas des données

## Performances

- ▶ Est-ce que ça marche bien ?
- ▶ Comment le savoir ?

# Perceptron de Rosenblatt

## ~~Table~~ Vocabulaire

- ▶ Neurone formel
- ▶ Poids synaptique
- ▶ Activation

## Version maths/stats/info

- ▶ Hyperplan, vecteur normal, etc
- ▶ Activation: signe (fonction de Heaviside, notée  $h$ )

## Apprentissage

- ▶ Cette fois, un algorithme !
- ▶ Principe: mise à jour successives des paramètres en fonction des erreurs



# Règle de Rosenblatt

## Algorithme

- ▶ Tirer aléatoirement  $w$
- ▶ **Tant qu'il y a des erreurs:**
  - ▶ **Pour** chaque exemple  $x$  et son étiquette  $y$ :
    - ▶ **Si**  $y\langle w, x \rangle < 0$ :  
 $w \leftarrow w + yx$

## Questions

- ▶  $y\langle w, x \rangle < 0$  ?
- ▶ *Tant qu'il y a des erreurs* ?
- ▶ Influence du  $w$  initial ?
- ▶ Impact de la mise à jour ?

## Théorème de Novikoff

Convergence si et seulement si classes linéairement séparables

# Règle de Widrow-Hoff


## Algorithme

- ▶ Tirer aléatoirement  $w$
- ▶ **Jusqu'à** convergence ou un nombre d'itérations maximum:
  - ▶ **Pour** chaque exemple  $x$  et son étiquette  $y$ :  
$$\hat{y} = h(\langle w, x \rangle)$$
$$w \leftarrow w + \alpha(y - \hat{y})x$$


## Questions

- ▶ Points communs et différences ?
- ▶  $\alpha$  ?
- ▶ Nombre d'itération maximum ?
- ▶ D'où ça vient ? Voir prochain cours


## Démonstration




## Démonstration




## Démonstration




## Démonstration



## Démonstration




## Démonstration







## Démonstration




## Démonstration



## Démonstration



## Démonstration



## Et le biais ?

### Astuce

- ▶ Départ: hyperplan en dimension  $d$ :  $\sum_{i=1}^d w_i x_i = b$
- ▶  $\sum_{i=1}^d w_i x_i - b = 0$
- ▶  $\sum_{i=1}^d w_i x_i + b(-1) = 0$
- ▶ Nouveau  $x = (x_1, \dots, x_d, -1)$
- ▶ Nouveau  $w = (w_1, \dots, w_d, b)$
- ▶ Arrivée: hyperplan en dimension  $d + 1$ :  $\sum_{i=1}^{d+1} w_i x_i = 0$

### Plus qu'une astuce

- ▶ Changement de la représentation des données
- ▶ Avant: modèle complexe, on ne sais pas quoi faire du biais
- ▶ Après: transformation des exemples, modèle simple et algorithmes déjà vus

# Conclusion

## Modèles et algorithme

- ▶ Modèle: forme de la frontière
- ▶ Apprentissage: trouver les paramètres à partir des données
- ▶ Hyper-paramètres: choisis à la main

## Plein de choix

- ▶ Comment les faire ?

## Évaluation

- ▶ La semaine prochaine

**Objectif: généraliser**