

## Plan du cours

### IA et science des données

Cours 9 – mardi 25 mars 2025

Clustering: algorithme des k-moyennes

Christophe Marsala

Sorbonne Université

LU3IN026 - 2024-2025

#### Apprentissage non-supervisé

- l'algorithme des k-moyennes (ou k-means)
- exemple
- évaluation du résultat
- en pratique
- conclusion

1 – Apprentissage non-supervisé –

## Rappels

- Classification : trouver des **classes** de descriptions
- Un ensemble de données sans classe connue
  - on recherche à faire des regroupements de descriptions similaires
  - on souhaite mettre en évidence des classes, des catégories
- But** : former des groupes de données qui se ressemblent
  - clustering** : faire des groupes parmi les données
  - cluster** : ensemble de données regroupées ensemble
- Exemple :
  - le **clustering hiérarchique**
  - l'**algorithme des k-moyennes**

1 – Apprentissage non-supervisé –

## Conclusion sur le clustering hiérarchique


- Algorithme très efficace sur des jeux de données assez réduit, sinon ça devient vite peu lisible
- Le nombre de classes à trouver n'est pas défini : il est estimé par l'étude du dendrogramme
- Les calculs sont très coûteux ! ( $\geq o(n^2)$ )

C. Marsala – 2025

LU3IN026 – cours 9 – 3

1 – Apprentissage non-supervisé –

## Exemple de dendrogramme final



C. Marsala – 2025

LU3IN026 – cours 9 – 4

1 – Apprentissage non-supervisé – l'algorithme des k-moyennes (ou k-means)

## Algorithme des k-moyennes (ou k-means)

- Un des algorithmes de clustering le plus courant
- Idée** : ceux qui se ressemblent, s'assemblent
  - trouver des clusters qui séparent les données de façon équitable
    - les clusters seront repérés par leur centre
- Mise en œuvre
  - choix du nombre de clusters à trouver :  $k > 1$ , entier naturel
  - mesure de la proximité entre données : **mesure de distance**
    - par exemple, distance euclidienne entre leurs descriptions
  - choisir  $k$  centres de clusters et affecter les données au cluster qui leur est le plus proche
  - modifier les  $k$  centres en fonction des données qui sont dans leur cluster

C. Marsala – 2025

LU3IN026 – cours 9 – 5

C. Marsala – 2025

LU3IN026 – cours 9 – 6

## APPRENTISSAGE NON-SUPERVISE (CLUSTERING)

BUT: CONSTRUIRE DES GROUPES D'EXEMPLES HOMOGENES ET DISTANTS

DEUX TYPES D'APPROCHES :

- 1) AGGLOMERATIVE : CLUSTERING HIÉRARCHIQUE
- 2) PAR PARTITIONNEMENT: → TROUVER UNE PARTITION DES EXEMPLES QUI OPTIMISE UN CRITÈRE

CHOISIR UN REPRÉSENTANT D'UN CLUSTER

K-MOYENNE = CENTRE DE GRAVITÉ DU CLUSTER  
K-MÉDOÏDE = UN EXEMPLE DU CLUSTER [1]

### NOTATIONS:

- $X = \{x_1, \dots, x_n\}$  EXEMPLES DE  $\mathbb{R}^d$
- ON CHERCHE K CLUSTERS  $C_1, \dots, C_K$  HOMOGENES ET DISTANTS LES UNS DES AUTRES
- $x_i = (x_{i1}, \dots, x_{id}) \quad \forall i=1 \dots n$
- $C_k$  = CLUSTER = SOUS-ENSEMBLE DE  $X$   
→ CONTIENT  $|C_k|$  EXEMPLES ( $= n_k$ )
- K-MOYENNES → PRÉSENTÉ PAR SON CENTROÏDE  $c_k$
- $c_k = (c_{k1}, \dots, c_{kd})$  = CENTRE DE GRAVITÉ
- $\forall j=1..d, \quad c_{kj} = \frac{1}{n_k} \sum_{x_i \in C_k} x_{ij}$  [2]

REMARQUE:

FONCTION CARACTÉRISTIQUE D'UN ENSEMBLE  $C_k \subseteq X$ :  
 $\chi_k: X \rightarrow \{0, 1\}$   
 $x \mapsto \chi_k(x) = \begin{cases} 1 & \text{si } x \in C_k \\ 0 & \text{sinon} \end{cases}$

ON PEUT ÉCRIRE:

$$\forall k, \forall j: \quad c_{kj} = \frac{1}{n_k} \sum_{i=1}^n \chi_k(x_i) x_{ij}$$

[3]

### ALGORITHME DES K-MOYENNES

ETANT DONNÉ:  $X$ ,  $K > 1$  (ET  $\epsilon > 0$  PETIT)

ÉTAPE 0: SÉLECTIONNER K EXEMPLES DE  $X$

- SOIT  $\tilde{x}_1, \dots, \tilde{x}_K$  CES EXEMPLES
- AFFECTER CHAQUE  $x \in X$  AU GROUPE DE L'EXEMPLE  $\tilde{x}_i$  DONT IL EST LE + PROXIME
  - PARTITION:  $P^{(0)} = \{C_1^{(0)}, \dots, C_K^{(0)}\}$
  - DÉTERMINER LES CENTRES DE CHAQUE GROUPE:  $c_1^{(0)}, \dots, c_K^{(0)}$  AVEC LES EXEMPLES DU GROUPE

[4]

ÉTAPE 1: RÉ-AFFECTER CHAQUE  $x \in X$  AU GROUPE

DONT IL EST LE PLUS PROXIME DU CENTRE

→ NOUVELLE PARTITION:  $P^{(1)} = \{C_1^{(1)}, \dots, C_K^{(1)}\}$

- RE-CALCULER LES NOUVEAUX CENTRES DES GROUPES:  $c_1^{(1)}, \dots, c_K^{(1)}$

[Q] L'OBJECTIF EST-IL ATTEINT?

⇒ CRITÈRE D'ARRÊT = CONVERGENCE

- SI OUI: LA PARTITION OBTENUE EST  $P$
- SI NON = NOUVELLE ÉTAPE

[5]

### OBJECTIF DES K-MOYENNES

TROUVER UNE PARTITION  $P = \{C_1, \dots, C_K\}$  DE  $X$  tq:

- 1)  $\forall k=1 \dots K, \quad |C_k| > 0$
- 2)  $C_1 \cup \dots \cup C_K = \bigcup_{k=1}^K C_k = X$
- 3)  $\forall k, k', \quad k \neq k' \Rightarrow C_k \cap C_{k'} = \emptyset$

REM: ETANT DONNÉ  $X$  ET  $K > 1$


[Q] QU'EST-CE QU'UNE BONNE PARTITION?

[6]

UNE BONNE PARTITION MINIMISE LES DISTANCES INTRA-CLUSTER

⇒ INERTIE D'UN CLUSTER : MESURE INTRA-CLUSTER

$$J_k = \sum_{x_i \in C_k} d_E^2(x_i, c_k)$$



MESURE DE LA DENSITÉ AUTOUR DE  $c_k$


→ CAPACITÉ DU CLUSTER [7]

INERTIE D'UNE PARTITION (CO-INERTIE)

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

$$J(\mathcal{P}) = \sum_{k=1}^K J_k$$

MESURE GLOBALE DE LA COMPACITÉ DES CLUSTERS



[8]

ALGORITHME DES K-MOYENNES : ARRÊT

→ CRITÈRE DE CONVERGENCE

$\mathcal{P}^{(t)}$  : PARTITION À L'ÉTAPE  $t$

$\mathcal{P}^{(t+1)}$  : PARTITION À L'ÉTAPE  $t+1$

$$|J(\mathcal{P}^{(t+1)}) - J(\mathcal{P}^{(t)})| < \epsilon$$

$\epsilon > 0$ , petit  
 $\epsilon \in \mathbb{R}^+$

[9]


BILAN : ALGORITHME DES K-MOYENNES

- HYPER-PARAMÈTRES : .  $K > 1$  ENTIER  
.  $\epsilon > 0$  RÉEL (PETIT)  
+ CHOIX DE L'INITIALISATION

- LIMITES DE L'ALGORITHME :  
. CHOIX DE L'INITIALISATION ?  
. CHOIX DE  $K$  ET AUSSI DE  $\epsilon$  ?

- RISQUES :  
→ CONVERGENCE VERS UN MINIMUM LOCAL  
→ CONVERGENCE PEUT ÊTRE LONGUE [10]

EXEMPLE EN 2 DIMENSIONS :




[11]

1 – Apprentissage non-supervisé – exemple


Un petit exemple

► Un ensemble de données quelconque



## Un petit exemple

- Convergence de l'algorithme : les centres ne changent pas



C. Marsala – 2025

LU3IN026 – cours 9 – 8

## Algorithme K-moyennes (2)

- Prérequis
  - $X$  : un ensemble de données (**base d'apprentissage**)
  - un entier naturel  $K > 0$  (le nombre de clusters à trouver)
  - une mesure de distance  $d$  entre deux exemples  $x$  et  $y$  :  $d(x, y)$
- Algorithme :
  1. choisir aléatoirement  $K$  exemples dans  $X$  comme premiers centres de clusters  $c_1, c_2, \dots, c_K$ 
    - chaque centre  $c_k$  définit un cluster  $C_k$
  2. affecter chaque  $x$  de  $X$  au cluster dont il est le plus proche
    - calculer  $d(x, c_1), \dots, d(x, c_K)$
    - affecter  $x$  au cluster  $C_k$  pour lequel  $d(x, c_k)$  est la plus petite
  3. mettre à jour les centres des clusters
    - $c_k$  est la **moyenne des descriptions** du cluster  $C_k$
  4. retourner à l'étape 2 jusqu'à ce que l'inertie globale ne change plus beaucoup
- Résultat
  - un ensemble de clusters  $C_1, \dots, C_K$

C. Marsala – 2025

LU3IN026 – cours 9 – 10

## Les K-moyennes en pratique


- Algorithme très simple à mettre en œuvre
  - algo ancien : James McQueen 1967
  - mais encore très utilisé !
  - nombreuses variantes...
- Quelques problèmes
  - quelle valeur pour  $K$  ?
  - **convergence** : la stabilisation peut être très longue à venir
  - sensible au choix initial des centres
  - quelle mesure de distance ?

C. Marsala – 2025

LU3IN026 – cours 9 – 12

## Clusters différents au final

- Le choix initial des centres est important ! (ici avec  $K = 2$ )



C. Marsala – 2025

LU3IN026 – cours 9 – 9

## Évaluation du résultat d'un clustering

- Évaluer la partition obtenue : mesurer sa **qualité**
  - différentes approches
  - utilisation des caractéristiques des clusters
- **Compacité** d'un cluster
  - évaluer combien les exemples sont proches les uns des autres
  - compacité intra-cluster
- **Séparabilité** des clusters
  - évalue combien les clusters sont éloignés les uns des autres
  - distance inter-clusters
- Mesure globale : **index d'une partition**
  - index de Dunn
  - index de Xie-Beni
  - ...

C. Marsala – 2025

LU3IN026 – cours 9 – 11

## K-moyenne : ce que l'on a vu

- **Objectif** : trouver une partition en  $K$  groupes (ou clusters)
  - **bonne partition** : minimise l'inertie globale intra-cluster
  - mesure de l'**inertie d'un cluster** : densité autour de son centre
- **Algorithme** : itérations successives jusqu'à convergence
  - affectation des exemples aux clusters
  - mise à jour des centres
  - arrêt si convergence ou itérations max

C. Marsala – 2025

LU3IN026 – cours 9 – 13