

MAPSI — cours 3 : Maximum de vraisemblance Maximum a posteriori

Pierre-Henri Wuillemin & Raphaël Fournier-S'niehotta
(& Nicolas Thome)

LIP6 / ISIR – Sorbonne Université, France

- ① Vraisemblance et prise de décision
- ② Estimation par maximum de vraisemblance (ML)
- ③ Estimation par maximum a posteriori (MAP)

② Vraisemblance et prise de décision

Vraisemblance d'un échantillon : loi discrète connue

- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon \implies les x_i = réalisations de variables aléatoires X_i
- Échantillon i.i.d. \implies les X_i sont **mutuellement** indépendants

$$\implies P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$



l'hypothèse i.i.d est essentielle !

Vraisemblance d'un échantillon dans le cas discret

- $L(\mathbf{x})$ = Vraisemblance de l'échantillon
- $L(\mathbf{x})$ = proba d'obtenir **cet** échantillon sachant la loi P

$$L(\mathbf{x}) = P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i)$$

Vraisemblance d'un échantillon : loi discrète connue

- pièce de monnaie : $P(\text{Pile}) = 0,75$ et $P(\text{Face}) = 0,25$
- jet de la pièce \Rightarrow expérience de Bernoulli
 \Rightarrow hypothèse i.i.d. vérifiée



- échantillon 1 :

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| P | P | F | F | P | P | F | P | P | P |
|---|---|---|---|---|---|---|---|---|---|

$$\Rightarrow L(\mathbf{x}) = \prod_{i=1}^7 P(\text{Pile}) \times \prod_{i=1}^3 P(\text{Face})$$

$$= 0,75^7 \times 0,25^3 \approx 0,002086$$

- échantillon 2 :

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| F | F | P | P | F | F | P | F | F | F |
|---|---|---|---|---|---|---|---|---|---|

$$\Rightarrow L(\mathbf{x}) = \prod_{i=1}^3 P(\text{Pile}) \times \prod_{i=1}^7 P(\text{Face})$$

$$= 0,75^3 \times 0,25^7 \approx 0,000026$$

Prévention des risques d'inondation (1/4)

- Plan de prévention des risques d'inondations (PPR-I) :
photos satellite SPOT5 \Rightarrow zones susceptibles d'être inondées



- 3 catégories de parcelles :
 - 1 inondables (P_I)
 - 2 partiellement inondables (PPI)
 - 3 non inondables (N_I)

Prévention des risques d'inondation (2/4)

- images en teintes de gris
- proba d'obtenir un niveau de gris n dépend du type de zone :

$$P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2)$$

$$\mu_1 = 100 \quad \sigma_1 = 20$$

$$P(n|PPI) = \mathcal{N}(\mu_2, \sigma_2^2)$$

$$\mu_2 = 85 \quad \sigma_2 = 5$$

- nouvelle image envoyée par SPOT5 :



- zone Z : niveau de gris $= n = 80$

Problème : zone $Z = PI$ ou PPI ?

Problème : zone $Z = PI$ ou PPI ?

- 2 hypothèses :
 - ➊ $\theta_1 = \text{« } Z \text{ est de type } PI \text{ »}$
 - ➋ $\theta_2 = \text{« } Z \text{ est de type } PPI \text{ »}$
- **Idée** : calcul du max de vraisemblance d'obtenir la zone Z sous θ_1 ou sous θ_2
- $L(\mathbf{x}, \theta_1) = p(80|PI)$, avec p fct de densité de $P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2)$

Rappel : la fonction de densité de $\mathcal{N}(\mu, \sigma^2)$ est :

$$p(x) = \frac{1}{\sqrt{2\pi}\cdot\sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right\}$$

Prévention des risques d'inondation (4/4)

Problème : zone $Z = PI$ ou PPI ?

- $P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2) = \mathcal{N}(100, 20^2)$
- $L(\mathbf{x}, \theta_1) = p(80|PI)$
$$= \frac{1}{\sqrt{2\pi} \times 20} \exp \left\{ -\frac{1}{2} \left(\frac{80-100}{20} \right)^2 \right\}$$
$$= \frac{1}{20\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \right\}$$
$$\approx 0,0121$$
- $P(n|PPI) = \mathcal{N}(\mu_2, \sigma_2^2) = \mathcal{N}(85, 5^2)$
- $L(\mathbf{x}, \theta_2) = p(80|PPI) = \frac{1}{\sqrt{2\pi} \times 5} \exp \left\{ -\frac{1}{2} \left(\frac{80-85}{5} \right)^2 \right\} \approx 0,0484$

Max de vraisemblance $\implies PPI$ plus probable

② ML : Estimation par maximum de vraisemblance

Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer : Θ

Exemple 1 :



$$X \in \{\text{pile, face}\}$$

$$P(X) = \begin{array}{|c|c|} \hline \text{pile} & \text{face} \\ \hline \theta_1 & \theta_2 \\ \hline \end{array} \implies \Theta = \{\theta_1, \theta_2\}$$

Exemple 2 : recommandations : $r_A \in \{1, 2, 3\}$, $r_B \in \{a, b\}$

$$P(r_A, r_B) = \begin{array}{|c|c|c|} \hline & a & b \\ \hline 1 & \theta_1 & \theta_2 \\ \hline 2 & \theta_3 & \theta_4 \\ \hline 3 & \theta_5 & \theta_6 \\ \hline \end{array} \implies \Theta = \{\theta_1, \dots, \theta_6\}$$

Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer : Θ
- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon \Rightarrow les x_i = réalisations de variables aléatoires X_i
- Échantillon i.i.d. \Rightarrow les X_i sont **mutuellement** indépendants

$$\Rightarrow P(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n P(X_i = x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon dans le cas discret

- $L(\mathbf{x}, \theta)$ = Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta)$ = proba d'obtenir **cet** échantillon sachant que $\Theta = \theta$

$$L(\mathbf{x}, \theta) = P(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n P(x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon : le cas continu

- Paramètre à estimer : Θ
- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon i.i.d. \implies les X_i sont mutuellement indépendants
- p : fonction de densité

$$\implies p(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n p(X_i = x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon dans le cas continu

- $L(\mathbf{x}, \theta) =$ Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta) = p(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n p(x_i | \Theta = \theta)$

Apprentissage de Θ par vraisemblance

- pièce de monnaie : $P(\text{Pile}) = \theta_1 = ???$ et $P(\text{Face}) = \theta_2 = ???$
- paramètre $\Theta = \text{proba de Pile} = \theta_1 = ???$
- échantillon :

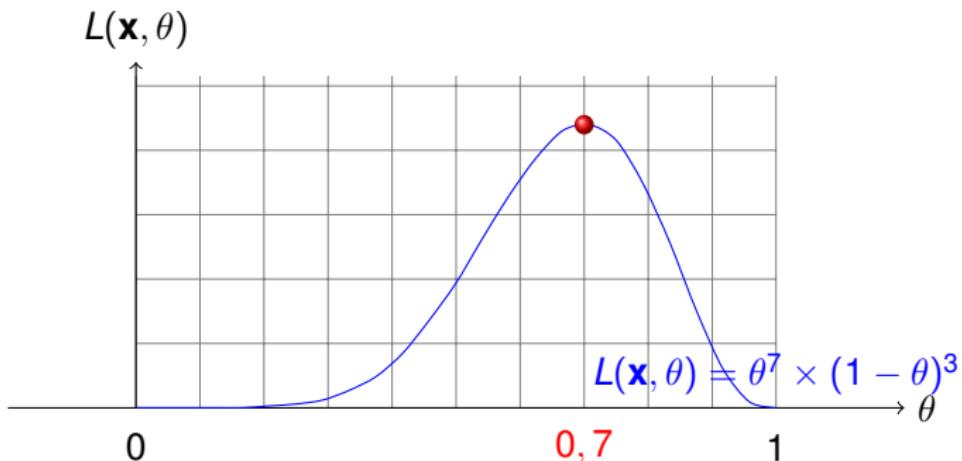
| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| P | P | F | F | P | P | F | P | P | P |
|---|---|---|---|---|---|---|---|---|---|

$$\implies L(\mathbf{x}, \Theta) = \prod_{i=1}^7 P(\text{Pile}|\Theta) \times \prod_{i=1}^3 P(\text{Face}|\Theta)$$

- $\theta_1 = 0,75 \implies L(\mathbf{x}, \theta_1) = 0,75^7 \times 0,25^3 \approx 0,002086$
- $\theta_2 = 0,5 \implies L(\mathbf{x}, \theta_2) = 0,5^7 \times 0,5^3 \approx 0,000976$
- $\theta_3 = 0,25 \implies L(\mathbf{x}, \theta_3) = 0,25^7 \times 0,75^3 \approx 0,000026$

$\implies \theta_1$ plus vraisemblable que θ_2 ou θ_3

Apprentissage de Θ par vraisemblance



solution optimale : $\theta^* = 0,7$

Estimateur du maximum de vraisemblance

- X : variable aléatoire sur la population
- X suit une loi de proba de paramètre Θ inconnu
- Θ : ensemble des valeurs possibles pour Θ
- \mathbf{x} : échantillon i.i.d.
- $T = f(X) = \text{estimateur du maximum de vraisemblance}$

défini par $\mathbf{x} \longmapsto t = f(\mathbf{x}) = \operatorname{Argmax}_{\theta \in \Theta} L(\mathbf{x}, \theta)$

$\implies t = \text{valeur } \theta \text{ de } \Theta \text{ pour laquelle la proba d'observer } \mathbf{x}$
était la plus grande

Calcul du maximum de vraisemblance

Problème : comment calculer le maximum de vraisemblance ?

- Argmax $_{\theta \in \Theta} L(\mathbf{x}, \theta) = \text{Argmax}_{\theta \in \Theta} P(x_1, \dots, x_n | \theta) = \text{Argmax}_{\theta \in \Theta} \prod_{i=1}^n P(x_i | \theta)$
- Certaines conditions de concavité et de dérивabilité
⇒ Argmax $_{\theta \in \Theta} L(\mathbf{x}, \theta)$ obtenu lorsque $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0$
- Argmax $_{\theta \in \Theta} L(\mathbf{x}, \theta) = \text{Argmax}_{\theta \in \Theta} \ln L(\mathbf{x}, \theta) = \text{Argmax}_{\theta \in \Theta} \sum_{i=1}^n \ln P(x_i | \theta)$

Argmax $_{\theta \in \Theta} \ln L(\mathbf{x}, \theta) = \text{maximum de la log vraisemblance}$

$$\Rightarrow \text{Argmax}_{\theta \in \Theta} L(\mathbf{x}, \theta) \text{ obtenu lorsque } \sum_{i=1}^n \frac{\partial \ln P(x_i | \theta)}{\partial \theta} = 0$$

Max de vraisemblance et loi binomiale

- pièce de monnaie
 - $X \in \{0, 1\}$, 0 \iff Face, 1 \iff Pile
 - $X \sim \mathcal{B}(1, p) \implies P(X = x|p) = p^x(1 - p)^{1-x}$
 - n lancers de la pièce \implies observations $\mathbf{x} = \{x_1, \dots, x_n\}$
 - $P(\mathbf{x}|p) = \prod_{i=1}^n P(x_i|p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}$
-

Problème : à partir de \mathbf{x} , peut-on raisonnablement déduire p ?

- maximum de vraisemblance :

$$\ln P(\mathbf{x}|p) = \sum_{i=1}^n [x_i \ln p + (1 - x_i) \ln(1 - p)]$$

$$\frac{\partial \ln P(\mathbf{x}|p)}{\partial p} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{n - \sum_{i=1}^n x_i}{1 - p} = 0 \implies p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

Max de vraisemblance et loi normale (1/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$; on suppose $\sigma = 1$
- paramètre $\Theta = \text{espérance } \mu$
- loi normale \Rightarrow vraisemblance :

$$L(\mathbf{x}, \theta) = \prod_{i=1}^n p(x_i | \theta) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2}(x_i - \theta)^2 \right\} \right]$$

- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = 0$
- $\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2$
- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \sum_{i=1}^n (x_i - \theta) = 0 \iff \theta = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$

Estimateur du maximum de vraisemblance : \bar{X}

Max de vraisemblance et loi normale (2/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$
- paramètre $\Theta = (\mu, \sigma^2)$
- Log vraisemblance :

$$\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

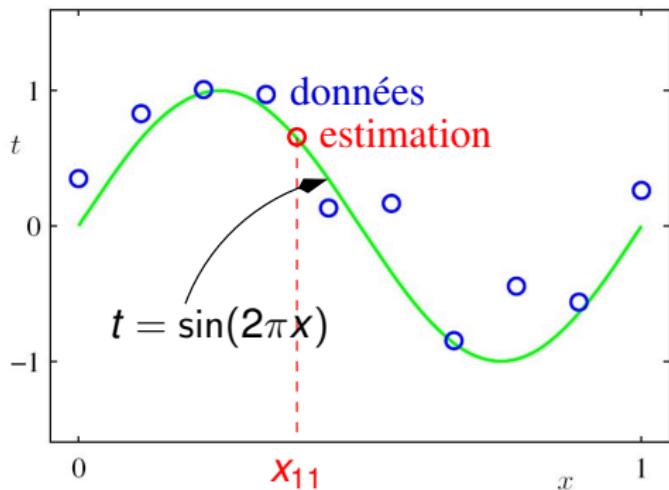
- Maximum de vraisemblance $\Rightarrow \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = 0$ et $\frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = 0$
- $$\begin{cases} \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases} \Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$
$$\Rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2$$

Estimateurs du maximum de vraisemblance : \bar{X} et s_n^2



estimateur de la variance biaisé : variance non corrigée

Problème d'ajustement (1/6)



Observations

(x_1, t_1)

\vdots

(x_{10}, t_{10})

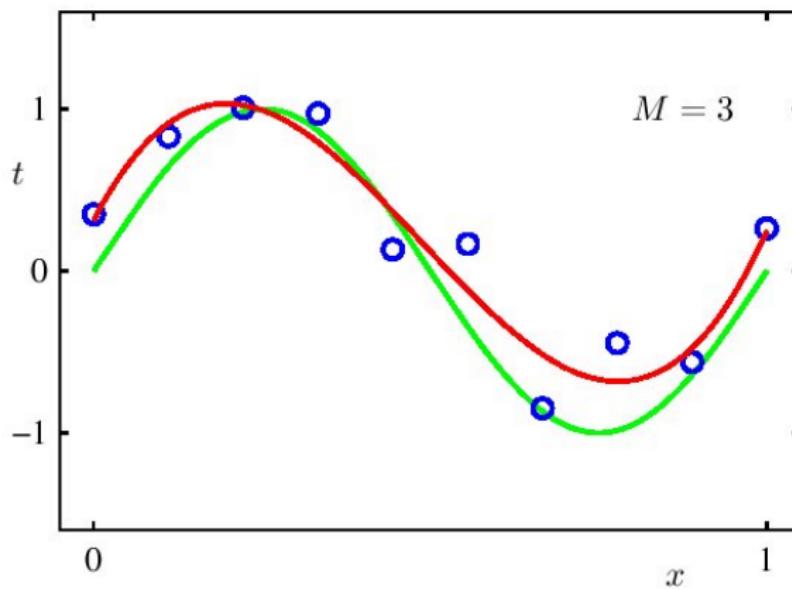
⇒ courbe $\sin(2\pi x)$ ⇒ estimation de t_{11}

⇒ reconnaissance de la courbe verte

Problème d'ajustement (2/6)

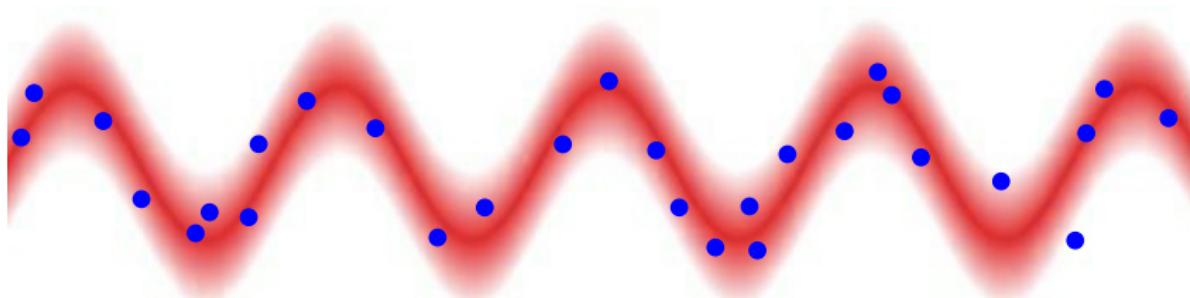
Idée : estimer la courbe verte par un polynôme :

$$y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^M w_j x^j$$



Problème d'ajustement (3/6)

Idée : les ordonnées des points bleus sont distribuées selon une loi normale autour de $y(x, \mathbf{w})$:



$$\Rightarrow P(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

Problème : comment trouver \mathbf{w} et σ^2 ?

\Rightarrow par maximum de vraisemblance

Problème d'ajustement (4/6)

$$P(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

- observations $\{(x_i, t_i), i = 1, \dots, n\}$
- $\mathbf{t} = \{t_1, \dots, t_n\}; \quad \mathbf{x} = \{x_1, \dots, x_n\}$
- observations \Rightarrow échantillon i.i.d

$$\begin{aligned}\Rightarrow P(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) &= \prod_{i=1}^n P(t_i|x_i, \mathbf{w}, \sigma^2) \\ &= \prod_{i=1}^n \mathcal{N}(t_i|y(x_i, \mathbf{w}), \sigma^2)\end{aligned}$$

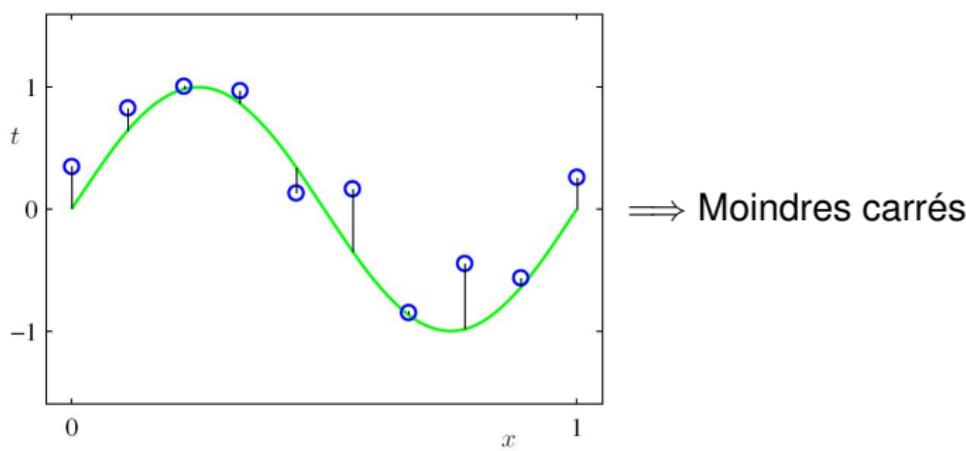
- Max de vraisemblance \Rightarrow calculer la log-vraisemblance :

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

Problème d'ajustement (5/6)

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- Maximum de log-vraisemblance \implies trouver \mathbf{w}_{ML} et σ_{ML}^2 qui maximisent $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$
- maximiser par rapport à $\mathbf{w}_{ML} \iff$ minimiser $\sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$



Problème d'ajustement (6/6)

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- maximiser $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$ par rapport à $\sigma^2 \implies \frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = 0$

- $\frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 - \frac{n}{2\sigma^4} \sigma^2 = 0$

$$\implies \sigma^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$$

$$\sigma_{ML}^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}_{ML}) - t_i]^2$$

② MAP : Estimation par maximum a posteriori

$$p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

- 3 lancers \Rightarrow observations : {Pile,Pile,Pile}



- Maximum de vraisemblance $\Rightarrow p_{ML} = 1$

\Rightarrow on considère que tout lancer de la pièce devrait tomber sur Pile

\Rightarrow résultat à l'encontre du bon sens

\Rightarrow autre estimateur : maximum a posteriori

Le modèle bayésien (1/4)

Maximum a posteriori \implies modèle bayésien

Modèle bayésien

événements : parties de $\mathcal{X} \times \Theta$, où :

- \mathcal{X} = l'espace des observations (échantillons) \mathbf{x} de taille n
 - Θ = espace des paramètres θ
 - famille des événements dotée d'une loi de proba Π
-
- *cas discret* : Π déterminée par les probas des événements élémentaires $\pi(\mathbf{x}, \theta)$
 - *cas continu* : Π déterminée par la densité jointe $\pi(\mathbf{x}, \theta)$



Max de vraisemblance : $\pi(\mathbf{x}|\theta)$ équivalent à $\pi(\mathbf{x}, \theta) = \pi(\mathbf{x}|\theta)\pi(\theta)$
car ArgMax

Le cas discret :

- $\pi(\mathbf{x}, \theta) = \Pi(X = \mathbf{x}, \Theta = \theta)$, où X, Θ variables aléatoires
- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \sum_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)$
- $\pi(\theta) = \Pi(\Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta)$
- $\pi(\mathbf{x}|\theta) = \Pi(X = \mathbf{x}|\Theta = \theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \Pi(\Theta = \theta|X = \mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

Probabilités a priori et a posteriori

- $\pi(\theta)$ = probabilité a priori de θ
- $\pi(\theta|\mathbf{x})$ = probabilité a posteriori de θ

Le cas continu :

- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \int_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) d\theta = \int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta$
- $\pi(\theta) = \Pi(\Theta = \theta) = \int_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) d\mathbf{x} = \int_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta) d\mathbf{x}$
- $\pi(\mathbf{x}|\theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

Le modèle bayésien (4/4)

Probabilités a priori et a posteriori

- $\pi(\theta)$ = probabilité a priori de Θ
= idée que l'on se fait de Θ avant observation
- $\pi(\theta|\mathbf{x})$ = probabilité a posteriori de Θ
= idée que l'on se fait de Θ après observation

- Formule de Bayes : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\pi(\mathbf{x})}$
- $$\left\{ \begin{array}{l} \text{cas discret : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \\ \text{cas continu : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta) d\theta} \end{array} \right.$$
- **Rappel :** $\pi(\mathbf{x}|\theta) = \text{vraisemblance de l'échantillon} = L(\mathbf{x}, \theta)$

Maximum a posteriori (MAP)

T estimateur du maximum a posteriori de Θ :

défini par $\mathbf{x} \longmapsto t = \operatorname{Argmax}_{\theta \in \Theta} \pi(\theta | \mathbf{x})$

- échantillon i.i.d de n observations
- $X = (X_1, \dots, X_n) \implies \mathbf{x} = (x_1, \dots, x_n)$ observation de X
- $$\begin{cases} \text{cas discret : } \pi(\theta | \mathbf{x}) = \frac{L(\mathbf{x}, \theta) \pi(\theta)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta) \pi(\theta)} \\ \text{cas continu : } \pi(\theta | \mathbf{x}) = \frac{L(\mathbf{x}, \theta) \pi(\theta)}{\int_{\theta \in \Theta} L(\mathbf{x}, \theta) \pi(\theta) d\theta} \end{cases}$$
- échantillon i.i.d $\implies \pi(\mathbf{x} | \theta) = L(\mathbf{x}, \theta) = \begin{cases} \prod_{i=1}^n P(x_i | \theta) & (\text{discret}) \\ \prod_{i=1}^n p(x_i | \theta) & (\text{continu}) \end{cases}$

MAP : retour sur la pièce de monnaie (1/6)

- pièce de monnaie $\Rightarrow X \in \{0, 1\}$

$0 \iff$ Face



$1 \iff$ Pile



- $X \sim \mathcal{B}(1, \theta) \Rightarrow P(X = x|\theta) = \theta^x(1 - \theta)^{1-x}$

- échantillon \mathbf{x} de 3 lancers $\Rightarrow \{\text{Pile}, \text{Pile}, \text{Pile}\}$



- Max de vraisemblance $\Rightarrow \theta_{ML} = 1$

\Rightarrow tous les lancers devraient tomber sur Pile

- Modèle bayésien : $\Theta = \{\theta_1 = 1, \theta_2 = 2/3, \theta_3 = 1/2, \theta_4 = 1/3\}$

- Info a priori : $\pi(\theta_1) = \frac{1}{32}, \pi(\theta_2) = \frac{1}{4}, \pi(\theta_3) = \frac{1}{2}, \pi(\theta_4) = \frac{7}{32}$

Problème : quelle est la valeur du maximum a posteriori ?

- Modèle bayésien : $\Theta = \{\theta_1 = 1, \theta_2 = 2/3, \theta_3 = 1/2, \theta_4 = 1/3\}$

- $L(\mathbf{x}, \theta_1) = \pi(\mathbf{x}|\theta_1) = \prod_{i=1}^3 P(x_i|\theta_1) = 1^3 \times 0^0 = 1$

- $L(\mathbf{x}, \theta_2) = \pi(\mathbf{x}|\theta_2) = \prod_{i=1}^3 P(x_i|\theta_2) = \frac{2}{3}^3 \times \left(1 - \frac{2}{3}\right)^0 = \frac{2}{3}^3 \approx 0,296$

- $L(\mathbf{x}, \theta_3) = \pi(\mathbf{x}|\theta_3) = \prod_{i=1}^3 P(x_i|\theta_3) = \frac{1}{2}^3 \times \left(1 - \frac{1}{2}\right)^0 = \frac{1}{2}^3 0,125$

- $L(\mathbf{x}, \theta_4) = \pi(\mathbf{x}|\theta_4) = \prod_{i=1}^3 P(x_i|\theta_4) = \frac{1}{3}^3 \times \left(1 - \frac{1}{3}\right)^0 = \frac{1}{3}^3 \approx 0,037$

MAP : retour sur la pièce de monnaie (3/6)

- Info a priori : $\pi(\theta_1) = \frac{1}{32}$, $\pi(\theta_2) = \frac{1}{4}$, $\pi(\theta_3) = \frac{1}{2}$, $\pi(\theta_4) = \frac{7}{32}$
- $\pi(\theta_1|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_1)\pi(\theta_1)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto 1 \times \frac{1}{32} = 0,03125$
- $\pi(\theta_2|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_2)\pi(\theta_2)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{2^3}{3} \times \frac{1}{4} \approx 0,074$
- $\pi(\theta_3|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_3)\pi(\theta_3)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{1^3}{2} \times \frac{1}{2} = 0,0625$
- $\pi(\theta_4|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_4)\pi(\theta_4)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{1^3}{3} \times \frac{7}{32} \approx 0,008$

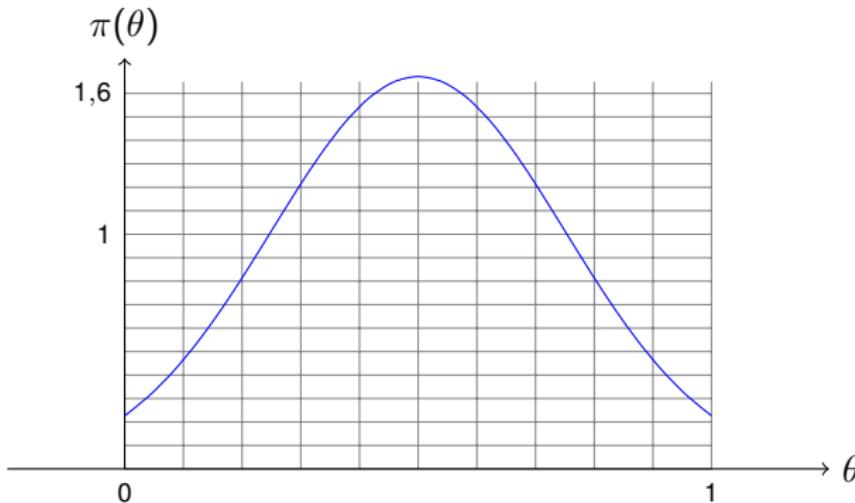
Max a posteriori : $\Theta = \theta_2 \implies X \sim \mathcal{B}(1, \theta_2) = \mathcal{B}(1, 2/3)$



probabilité que la pièce tombe sur Face $\neq 0$

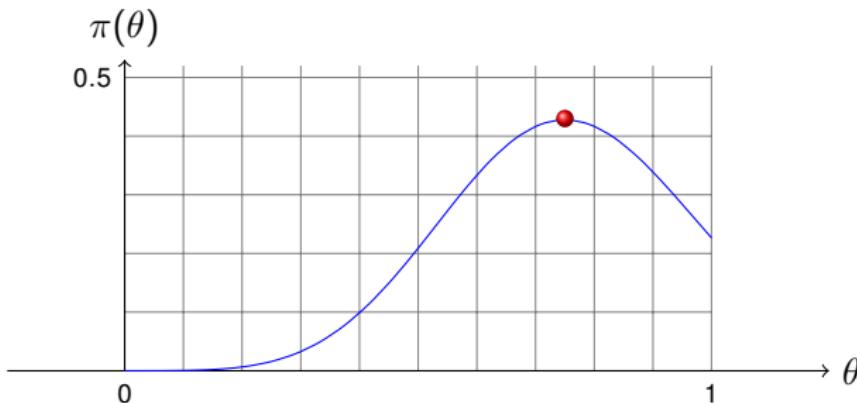
MAP : retour sur la pièce de monnaie (4/6)

- Modèle bayésien : $\Theta \in [0, 1]$
- Info a priori : $\Theta \sim \text{loi normale tronquée } (\mu = 1/2, \sigma = 1/4)$:
- densité : $\pi(\theta) = \begin{cases} \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}$



MAP : retour sur la pièce de monnaie (5/6)

$$\begin{aligned}\pi(\theta|\mathbf{x}) &= \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\int_{\theta' \in \Theta} L(\mathbf{x}, \theta')\pi(\theta')} \propto L(\mathbf{x}, \theta)\pi(\theta) = \theta^3 \times \pi(\theta) \\ &\propto \begin{cases} \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}\end{aligned}$$



solution optimale : $\theta = 0,75$

MAP : retour sur la pièce de monnaie (6/6)

$$\pi(\theta|\mathbf{x}) \propto \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) \text{ pour } \theta \in [0, 1]$$

$$\implies \log \pi(\theta|\mathbf{x}) = 3 \log \theta - \frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2 + \text{constante}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = \frac{3}{\theta} - \frac{\theta-\mu}{\sigma^2}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = 0 \Leftrightarrow \theta^2 - \mu\theta - 3\sigma^2 = 0$$

$$\implies \theta = 0,75$$

calcul de la distribution a posteriori : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)d\theta}$

⇒ si $\pi(\mathbf{x}|\theta)\pi(\theta)$ complexe analytiquement alors calcul de l'intégrale compliqué

Lois conjuguées

- $\pi(\theta)$: loi a priori
- $\pi(\mathbf{x}|\theta)$: fonction de vraisemblance
- $\pi(\theta|\mathbf{x})$: distribution a posteriori
- $\pi(\theta)$ et $\pi(\mathbf{x}|\theta)$ sont conjuguées si $\pi(\theta|\mathbf{x})$ appartient à la même famille de lois que $\pi(\theta)$

Lois conjuguées : exemple de la pièce de monnaie

- pièce de monnaie $\Rightarrow X \in \{0, 1\}$: 0 \iff  1 \iff 

- $X \sim \mathcal{B}(1, \theta) \Rightarrow$ vraisemblance d'un échantillon :

$$\pi(\mathbf{x}|\theta) = \theta^x (1-\theta)^{n-x}, \text{ avec } x = \#\{x_i = 1\}$$

\Rightarrow loi binomiale

Distribution de probabilité Beta

Loi Beta : $\text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$

avec $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$

Espérance = $\frac{a}{a+b}$ Variance = $\frac{ab}{(a+b)^2(a+b+1)}$

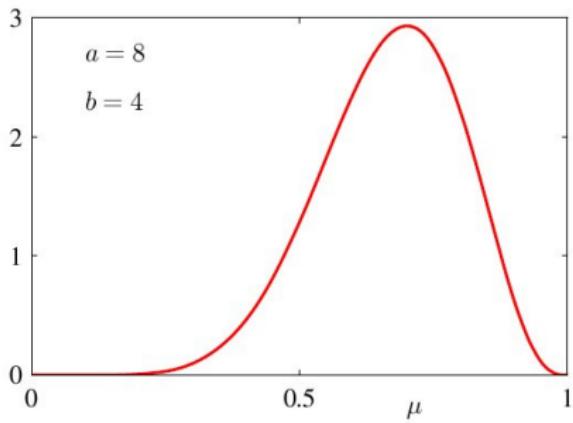
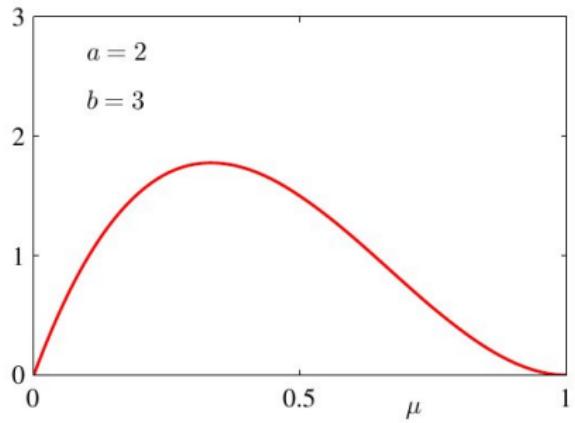
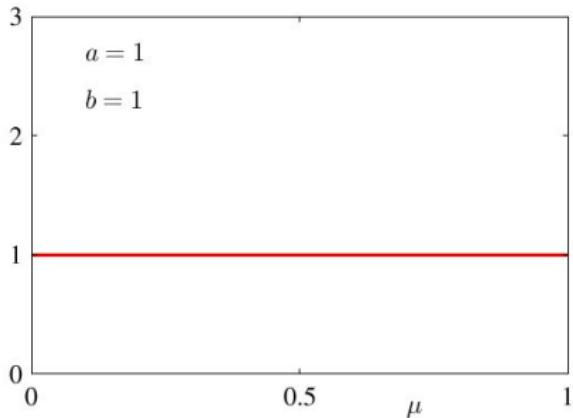
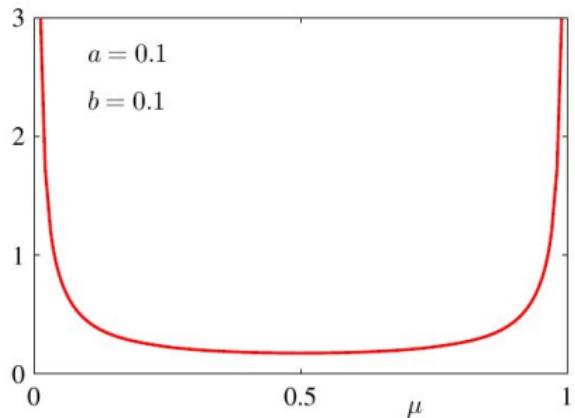
\Rightarrow loi Beta et loi binomiales conjuguées

Lois conjuguées : loi binomiale et loi Beta

- loi a priori : $\pi(\theta) = \text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}$
- fonction de vraisemblance : $\pi(\mathbf{x}|\theta) = \theta^x(1-\theta)^{n-x}$, avec $x = \#\{x_i = 1\}$
- loi a posteriori : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \propto \pi(\mathbf{x}|\theta)\pi(\theta)$
- loi a posteriori : $\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1}(1-\theta)^{b+n-x-1}$

$$\implies \pi(\theta|\mathbf{x}) \sim \text{Beta}(\theta, x+a, b+n-x)$$

La loi Beta



Comparaison MAP – maximum de vraisemblance

- pièce de monnaie $\Rightarrow X \in \{0, 1\}$: $0 \Leftrightarrow$



1 \Leftrightarrow



- Max de vraisemblance :

$$\pi(\mathbf{x}|\theta) = \theta^x(1-\theta)^{n-x} \Rightarrow \text{Beta}(\theta, x+1, n-x+1)$$

- Max a posteriori :

$$\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1}(1-\theta)^{b+n-x-1} \Rightarrow \text{Beta}(\theta, x+a, n-x+b)$$

\Rightarrow Max de vraisemblance \Leftrightarrow Max a posteriori avec $a = 1$ et $b = 1$

Or $\text{Beta}(\theta, 1, 1) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} = \text{constante}$

Max de vraisemblance \Leftrightarrow Max a posteriori avec a priori uniforme



$n \rightarrow +\infty \Rightarrow$ max de vraisemblance \approx max a posteriori

\Rightarrow l'a priori devient négligeable

Loi normale et loi conjuguée

- fonction de vraisemblance = loi normale, σ^2 connue
 \Rightarrow loi a priori conjuguée : loi Γ

La loi Γ

- $X \sim \Gamma(x, k, \theta)$
- fonction de densité de la loi Γ :

$$f(x, k, \theta) = x^{k-1} \frac{e^{-x/\theta}}{\theta^k \Gamma(k)} \quad \forall x, k, \theta > 0$$

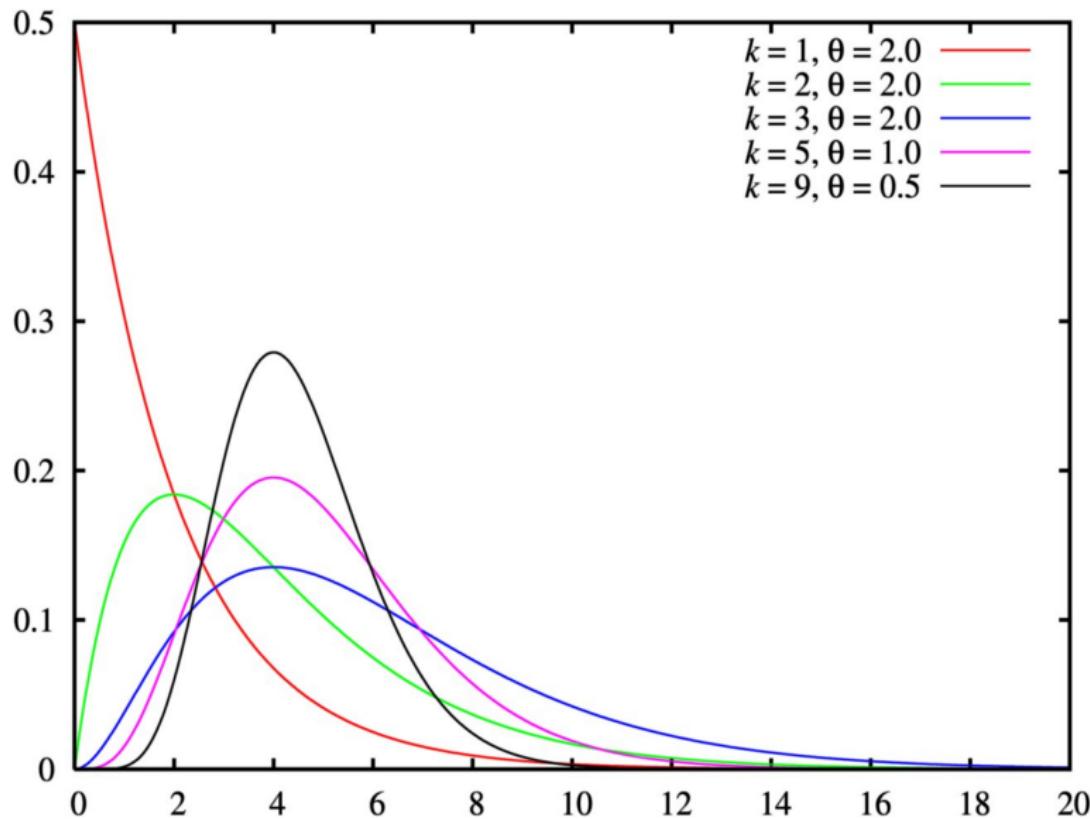
- $\Gamma(k) = \int_0^{+\infty} t^{k-1} e^{-t} dt$
- $E(X) = k\theta, \quad V(X) = k\theta^2$



Lorsque k entier : $\Gamma(x, k, \theta) =$ loi de k variables indépendantes suivant une loi exponentielle d'espérance θ

- Familles de lois conjuguées :
http://en.wikipedia.org/wiki/Conjugate_prior

Loi Gamma



Prévention des risques d'inondation (1/3)

- Plan de prévention des risques d'inondations (PPR-I) :
photos satellite SPOT5 \Rightarrow zones susceptibles d'être inondées



- 3 catégories de parcelles :
 - 1 inondables (P_I)
 - 2 partiellement inondables (PPI)
 - 3 non inondables (N_I)

Prévention des risques d'inondation (2/3)

- images en teintes de gris
- proba d'obtenir un niveau de gris n dépend du type de zone :

$$P(n|PI) = \mathcal{N}(100, 20^2) \quad P(n|PPI) = \mathcal{N}(85, 5^2)$$

- nouvelle image envoyée par SPOT5 :



- zone Z : niveau de gris $= n = 80$
- Connaissance a priori : 60% de PI , 10% de PPI , 30% de NI

Problème : zone $Z = PI$ ou PPI ?

Prévention des risques d'inondation (3/3)

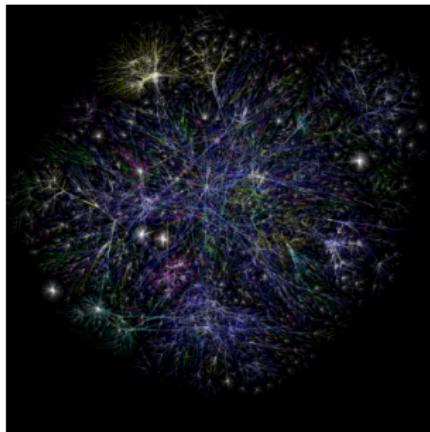
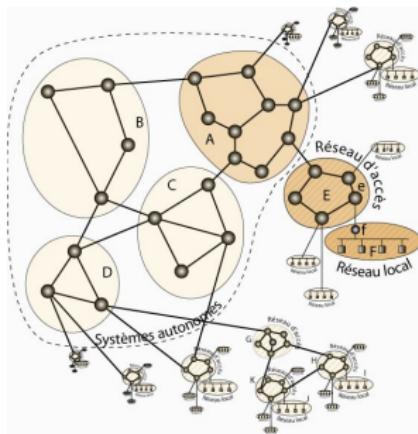
Problème : zone $Z = PI$ ou PPI ?

- 2 hypothèses :
 - ➊ $\theta_1 = \text{« } Z \text{ est de type } PI \text{ »}$
 - ➋ $\theta_2 = \text{« } Z \text{ est de type } PPI \text{ »}$
- **Idée** : calcul du MAP d'obtenir la zone Z sous θ_1 ou sous θ_2
- $\pi(\theta_1|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_1)\pi(\theta_1)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$ $\pi(\theta_2|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_2)\pi(\theta_2)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$
- Rappel cours 4 : $L(\mathbf{x}, \theta_1) \approx 0,0121$ $L(\mathbf{x}, \theta_2) \approx 0,0484$
- a priori : $\pi(\theta_1) = 0,6$ $\pi(\theta_2) = 0,1$
- $\pi(\theta_1|\mathbf{x}) = \frac{0,0121 \times 0,6}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$ $\pi(\theta_2|\mathbf{x}) = \frac{0,0484 \times 0,1}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$

MAP \implies parcelle inondable (PI)

Analyse d'un trafic réseau (1/4)

- Réseau informatique : transfert de paquets



- **Problème** : analyse des paquets perdus sur un sous-réseau
- X : variable aléatoire « nombre de paquets envoyés jusqu'à bonne réception »
- X loi géométrique : $P(X = n) = (1 - p)^{n-1} p$
- p : probabilité qu'un paquet soit correctement transmis

- observation de 7 réalisations de X :

| | | | | | | |
|---|---|---|---|---|---|---|
| 2 | 3 | 8 | 3 | 4 | 7 | 8 |
|---|---|---|---|---|---|---|

Estimation de p ?

- estimation par ML
- estimation par MAP

① estimation par max de vraisemblance

| | | | | | | |
|---|---|---|---|---|---|---|
| 2 | 3 | 8 | 3 | 4 | 7 | 8 |
|---|---|---|---|---|---|---|

- vraisemblance : $L(\mathbf{x}, \theta) = \prod_{i=1}^7 P(x_i|\theta)$

θ = estimation de p

- observations $\Rightarrow L(\mathbf{x}, \theta) = (1 - \theta)^{28} \theta^7$

$$\Rightarrow \ln L(\mathbf{x}, \theta) = 28 \ln(1 - \theta) + 7 \ln \theta$$

$$\Rightarrow \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = \frac{-28}{1 - \theta} + \frac{7}{\theta} = \frac{7 - 35\theta}{\theta(1 - \theta)}$$

$$\Rightarrow \text{maximum de vraisemblance} = \theta = 0,2$$

② estimation par max de vraisemblance

| | | | | | | |
|---|---|---|---|---|---|---|
| 2 | 3 | 8 | 3 | 4 | 7 | 8 |
|---|---|---|---|---|---|---|

-
- A priori : $\pi(\theta) = \text{Beta}(\theta, 2, 15) = \frac{\Gamma(17)}{\Gamma(2)\Gamma(15)}\theta^1(1-\theta)^{14}$
 - $\text{Argmax}_\theta \pi(\theta|\mathbf{x}) = \text{Argmax}_\theta L(\mathbf{x}, \theta)\pi(\theta)$
 $= \text{Argmax}_\theta [(1-\theta)^{28}\theta^7] \times [(1-\theta)^{14}\theta]$
 $= \text{Argmax}_\theta (1-\theta)^{42}\theta^8$
 $= \text{Argmax}_\theta 42 \ln(1-\theta) + 8 \ln \theta$
 $\implies \theta_{MAP} = 0,16$