

Comparaison de Q-learning et Dyna-Q (Softmax) dans des labyrinthes sans murs

Yuxiang ZHANG, Kenan Alsafadi

Introduction

Cette étude compare Q-learning (ε -greedy) et Dyna-Q (softmax) selon trois critères : performance finale, efficacité en échantillons et en temps. Les tests sont menés sur trois labyrinthes sans murs (3×3 , 5×5 , 8×8) avec MazeMDP (ratio=0).

Méthodologie

Algorithmes Q-learning met à jour $Q(s, a)$ avec la règle standard. Dyna-Q ajoute n_{updates} mises à jour simulées à partir d'un modèle déterministe (transitions, récompenses, terminaison). L'exploration utilise ε -greedy pour Q-learning et softmax (β) pour Dyna-Q.

Environnements Labyrinthes 3×3 , 5×5 , 8×8 , départ en haut à gauche, objectif en bas à droite. Récompense +1 pour l'objectif, -0.01 par pas, $\gamma = 0.9$. Retour actualisé $G = \sum_t \gamma^t r_t$.

Optimisation Optuna (30 essais, 3 seeds) optimise $\alpha \in [10^{-3}, 1]$, $\varepsilon \in [0.02, 0.4]$ pour Q-learning ; α , $\beta \in [0.5, 20]$, $n_{\text{updates}} \in [0, 10]$ pour Dyna-Q. Objectif : retour final après 20 000 pas (évaluation gloutonne sur 3 épisodes).

Protocole Pour chaque configuration optimisée, 20 runs (seeds différentes). Évaluation tous les 500 pas sur 30 épisodes (politique gloutonne). Métriques : AUC (échantillons/temps), seuil 0.9 (non atteint car retour max théorique < 0.9). Tests de Welch ($\alpha = 0.05$).

Résultats


TABLE 1 – Meilleurs hyperparamètres et métriques moyennes (20 runs). Les p-valeurs significatives ($p < 0.05$) sont en gras.

	3×3		5×5		8×8	
	QL	Dyna	QL	Dyna	QL	Dyna
α	0.00151	0.00874	0.03261	0.1476	0.1752	0.01366
ε	0.1723	—	0.1619	—	0.0365	—
β	—	1.964	—	6.286	—	6.759
n_{upd}	—	9	—	4	—	8
Retour final	0.6561	0.6561	0.0000	0.4305	0.0000	0.1830
p (retour final)	1 (NS)		<0.001		<0.001	
AUC (échantillons)	11088	12794	0	8367	0	1650
p (AUC steps)	<0.001		<0.001		<0.001	
AUC (temps)	0.629	3.061	0	1.494	0	0.764
p (AUC time)	<0.001		<0.001		<0.001	


NS : non significatif. Seuil 0.9 non atteint (retour max théorique : $3 \times 3 = 0.66$, $5 \times 5 = 0.43$, $8 \times 8 = 0.23$).

Conclusion


Dyna-Q surpasse significativement Q-learning en efficacité d'échantillons et en temps pour les labyrinthes 5×5 et 8×8 (retour final $p < 0.001$, AUC $p < 0.001$). Pour 3×3 , les deux algorithmes atteignent le même



Retour moyen d'évaluation (politique gloutonne) en fonction du nombre de transitions collectées. Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(retour final)=1, p(AUC_échantillons)=6.02e-06.



Retour moyen d'évaluation (politique gloutonne) en fonction du temps de calcul (wall-clock). Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(AUC_temps)=3.19e-25, p(temps-à-seuil)=nan.




Retour moyen d'évaluation (politique gloutonne) en fonction du nombre de transitions collectées. Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(retour final)=2.27e-303, p(AUC_échantillons)=2.64e-41.

(a) 3×3, échantillons


(b) 3×3, temps

(c) 5×5, échantillons




Retour moyen d'évaluation (politique gloutonne) en fonction du temps de calcul (wall-clock). Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(AUC_temps)=1.57e-18, p(temps-à-seuil)=nan.

(d) 5×5, temps



Retour moyen d'évaluation (politique gloutonne) en fonction du nombre de transitions collectées. Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(retour final)=4.57e-08, p(AUC_échantillons)=7.16e-11.

(e) 8×8, échantillons



Retour moyen d'évaluation (politique gloutonne) en fonction du temps de calcul (wall-clock). Bande d'incertitude : intervalle [p10, p90] (percentiles 10%-90%) sur N=20 runs. Seuil indiqué : return=0.90. Tests de significativité (Welch) : p(AUC_temps)=9.59e-12, p(temps-à-seuil)=nan.

(f) 8×8, temps

FIGURE 1 – Retour moyen d'évaluation (politique gloutonne) en fonction des échantillons et du temps. Bande d'incertitude : intervalle [p10,p90] sur 20 runs. Lignes pointillées : seuil 0.9 et optimum théorique 1.0.

retour final (0.6561), mais Dyna-Q a une AUC plus élevée ($p < 0.001$), indiquant une progression plus rapide. Le seuil de 0.9 n'est jamais atteint car le retour maximal théorique est inférieur (0.23 à 0.66). En environnement déterministe tabulaire, l'utilisation d'un modèle interne (Dyna-Q) accélère nettement l'apprentissage.